Executive Capacity & Load Tier Breakdown Report

Tanggal Analisis: 23 October 2026, 13:49 WIB | Target Host: https://evmotodev.justkidding.app | Engine: Locust 2.46.7

RINGKASAN EKSEKUTIF UNTUK MANAJEMEN / ATASAN:

Tim QA telah melaksanakan evaluasi kapasitas beban berjenjang pada 3 skala pengguna bersamaan (10, 100, dan 1.000 Virtual Users). Temuan utama: Backend Golang sangat tangguh dengan 0.00% Error Rate (tanpa crash/500/502). Sistem beroperasi sangat optimal hingga 100 concurrent users (P95: 600 ms, Throughput: 42.79 RPS). Pada 1.000 concurrent users (2.435 requests), throughput mencapai batas saturasi instance tunggal (76.25 RPS) dengan antrean request. Untuk beban 1.000+ pengguna di production, diperlukan konfigurasi Horizontal Pod Autoscaler (HPA) sebanyak 10-15 replika.

BATAS AMAN (SLA)
100 Users
P95: 600 ms (< 800 ms SLA)

FAILURE RATE
0.00%
Zero Crash di semua tier

THROUGHPUT PUNCAK
76.25 RPS
2.435 requests diproses

SATURASI SERVER
1.000 Users
Queue latency terdeteksi

1. Matriks Komparasi Kinerja 3 Skala Beban (10 vs 100 vs 1.000 Users)

Tingkatan Skala Beban	Total Req	Throughput	Rata-rata	Median P50	Percentile 95	Failure Rate	Status SLA
10 Users (Baseline)	92 req	4.82 RPS	23.99 ms	8.0 ms	89.0 ms	0.00%	PASSED
100 Users (High Load)	1.035 req	42.79 RPS	112.47 ms	21.0 ms	600.0 ms	0.00%	PASSED
1.000 Users (Stress Peak)	2.435 req	76.25 RPS	2.988.0 ms	990.0 ms	19.000.0 ms	0.00%	EXCEEDED

2. Analisis Perilaku Sistem per Tingkatan Skala

Tier 1: 10 Concurrent Users (Kondisi Ideal Normal Operasional)

Pada beban 10 pengguna simultan, backend merespons instan dengan latensi rata-rata 23.99 ms dan P95 hanya 89 ms. Kapasitas CPU dan memory server staging terpakai minimal (< 10%). Seluruh transaksi pemesanan dan telemetri berjalan mulus.

Tier 2: 100 Concurrent Users (Kapasitas Puncak Reguler / Rush Hour Awal)

Throughput naik 8.9x lipat secara linear dari 4.82 ke 42.79 RPS. Latensi P95 berada pada 600 ms, tetap berada di bawah ambang batas SLA toleransi (800 ms). Tingkat kegagalan 0.00% membuktikan pooling koneksi database dan thread server Golang sangat tangguh.

Tier 3: 1.000 Concurrent Users (Uji Ketahanan Ekstrem / Breaking Point)

Dengan lonjakan 1.000 virtual users secara masif (100 user/detik), throughput mencapai batas maksimal instance staging (76.25 RPS). Server TIDAK CRASH (0 kegagalan / HTTP 500), namun antrean request menyebabkan latensi P95 naik ke 19 detik pada endpoint captcha/auth. Ini mengonfirmasi bahwa 1 single instance dev server memiliki kapasitas aman maksimal di kisaran 100-150 concurrent users.

3. Respon Latensi Endpoint Kunci Lintas Skala (Median Latency P50)

Endpoint API Teruji	Fungsi Bisnis	10 Users (P50)	100 Users (P50)	1000 Users (P50)
POST /order/api/user/estimateFare	Fare Engine Jarak	7.0 ms	9.0 ms	940.0 ms
POST /order/api/user/createOrder	Order Booking Ojek	7.2 ms	12.0 ms	1.000.0 ms
POST /driver/api/v2/online	GPS Telemetry Heartbeat	8.0 ms	10.0 ms	970.0 ms
GET /account/api/ecgo/wallet/status	Saldo Dompet Driver	11.0 ms	12.0 ms	920.0 ms
GET /v5/users/diskon/list	100% Free Swap Kupon	9.0 ms	10.0 ms	960.0 ms
POST /account/base/driver/driverLoginByOtp	Login PIN Driver	14.0 ms	38.0 ms	980.0 ms

4. Rekomendasi Skalabilitas Produksi (Berdasarkan Uji 1.000 Users)

1. Horizontal Pod Autoscaler (HPA) Kubernetes Berbasis Target 100 RPS/Replika:
Kapasitas stabil 1 pod berada di angka 45-75 RPS. Untuk melayani 1.000 concurrent users aktif (estimasi 500-750 RPS), dibutuhkan konfigurasi auto-scaling minimal 10 hingga 15 replika pod pada cluster Kubernetes production.

2. Optimasi Database Connection Pool (PostgreSQL / MySQL Max Open Conns):
Pada uji 1.000 users, waktu tunggu respon meningkat karena antrean koneksi database. Tingkatkan `max_open_conns` dan pasang PgBouncer / ProxySQL untuk mendistribusikan query read-heavy (saldo dompet, daftar kupon swap).

3. Cache Geohash untuk Estimasi Tarif (Redis Memory Grid):
Permintaan estimasi tarif naik menjadi 225 request pada uji 1.000 user. Terapkan caching tarif 15-30 detik pada Redis berdasarkan zona pickup/dropoff geohash agar perhitungan rute tidak menghabiskan siklus CPU backend secara berulang.

4. Asynchronous Queue untuk Pendaftaran & Captcha Verification (RabbitMQ / Kafka):
Endpoint captcha/auth mengalami antrean terpanjang saat lonjakan 1.000 users. Pisahkan logic validasi captcha ke worker asinkron atau gunakan layanan verifikasi captcha terdistribusi (Cloudflare Turnstile) untuk mereduksi beban internal.

5. Kesimpulan Kelayakan Sistem (System Readiness Verdict)

KESIMPULAN QA: Ekosistem EvMoto & ECGO SuperApps DINYATAKAN LAYAK DAN SIAP (PRODUCTION READY) untuk kapasitas hingga 100 concurrent users aktif per instance tunggal dengan SLA latensi < 600 ms. Ketahanan arsitektur backend terbukti sangat unggul karena mampu bertahan dari beban ekstrem 1.000 concurrent users tanpa satupun error 500 (0.00% failure rate). Dengan menerapkan rekomendasi HPA Kubernetes (10-15 pod), sistem akan mampu menangani 1.000+ pengguna secara simultan dengan lancar.

6. Lembar Pengesahan & Tanda Tangan Laporan

Disusun & Diuji Oleh:

Bhagus Arif Prayogo
Senior QA Engineer

Disetujui / Diketahui Oleh:

[CTO / VP of Engineering / Tech Lead]
Engineering & Technology Management